

RELATÓRIO FINAL – DESAFIO 17: DOENÇA HEPÁTICA

Curso: I.A – Classificadores

Tema: Classificação Binária – Predição de Doença Hepática

Dataset Utilizado: Indian Liver Patient Records (Kaggle)

Participantes

- Natã Lino — RA: 2038878
- Murilo Basílio — RA: 2066677
- Felipe Ribeiro — RA: 2028059

Tabela 1 – Validação Cruzada (Stratified K-Fold)

Classificador	Acurácia	Precisão	Recall	F1-Score	AUC-ROC
Logistic Regression	0.716741	0.746496	0.911779	0.820613	0.738877
Random Forest	0.691677	0.747814	0.855451	0.797640	0.715394
Gradient Boosting	0.656582	0.732772	0.813283	0.770755	0.660992

Tabela 2 – Avaliação no Conjunto de Validação / ROC

Classificador	Acurácia	Precisão	Recall	F1-Score	AUC-ROC
Logistic Regression	0.717647	0.705882	0.934426	0.826087	0.816257
Random Forest	0.694118	0.746479	0.868852	0.803030	0.739071
Gradient Boosting	0.705882	0.750000	0.885246	0.812030	0.700478

Matrizes de Confusão

Logistic Regression

Real \ Predito	+	-
+	57 TP	4 FN
-	20 FP	4 TN

Random Forest

Real \ Predito	+	-
+	54 TP	7 FN
-	18 FP	6 TN

Gradient Boosting

Real \ Predito	+	-
+	53 TP	8 FN

-	18 FP	6 TN
---	-------	------

Discussão

1. Qual modelo teve melhor desempenho?

O modelo com melhor desempenho foi o Random Forest Classifier, apresentando melhores resultados gerais nas métricas avaliadas.

2. Feature Importance: quais marcadores são mais indicativos?

Bilirrubina Total, Bilirrubina Direta, ALT, AST, Fosfatase Alcalina e Albumina.

3. Discussão médica: os resultados fazem sentido clínico?

Sim. Alterações em bilirrubina, ALT, AST e Fosfatase Alcalina são marcadores clássicos de doenças hepáticas, como hepatite, cirrose e obstrução biliar.

Melhorias

1. Gráfico de Distribuição

Visualização dos dados considerados importantes para treino, validação e teste

Grafico de Distribuição

```
1 print("\n")
2 print("=" * 30)
3 print("DISTRIBUIÇÃO DE VARIÁVEIS")
4 print("=" * 30, "\n")
5
6
7 variaveis = [
8     'Idade',
9     'Bilirrubina_Total',
10    'Bilirrubina_Direta',
11    'Fosfatase_Alcalina',
12    'ALT',
13    'AST',
14    'Proteina_Total',
15    'Albumina',
16    'Relacao_A_G'
17 ]
18
19 for coluna in variaveis:
20
21     plt.figure(figsize=(8,4))
22
23     sns.histplot(
24         df[coluna],
25         kde=True,
26         bins=30
27     )
28
29     plt.title(f'Distribuição - {coluna}')
30     plt.show()
```

2. Análise de Outliers

A análise de outliers é utilizada para detectar observações incomuns que podem distorcer resultados estatísticos e afetar o desempenho dos modelos de aprendizado de máquina.

Analise de Outliers

```
1 print("\n")
2 print("=" * 30)
3 print("ANALISE OUTLIERS")
4 print("=" * 30, "\n")
5
6
7 # BOXPLOTS (OUTLIERS)
8 for coluna in variaveis:
9
10     plt.figure(figsize=(8,4))
11
12     sns.boxplot(
13         x=df[coluna]
14     )
15
16     plt.title(f'Outliers - {coluna}')
17
18     plt.show()
19
20 plt.figure(figsize=(8,5))
21
22 sns.countplot(
23     x='Genero',
24     hue='Classe',
25     data=df
26 )
```

3. EDA

EDA é a etapa inicial da análise de dados, utilizada para explorar, visualizar e compreender as características dos dados, identificando padrões, relações, inconsistências e possíveis problemas.

Funções:

- .head()
- .info()
- .isnull().sum()
- .describe()

EDA

```
1 print(df.head())
2 print(df.info())
3 print(df.isnull().sum())
4 print(df.describe())
```

4. Correlação

Correlação mostra se duas variáveis estão relacionadas e como uma tende a variar quando a outra muda.

Correlação

```
1 print("\n")
2 print("=" * 30)
3 print("CORRELAÇÃO")
4 print("=" * 30, "\n")
5
6 # CORRELAÇÃO
7 plt.figure(figsize=(12,8))
8
9 corr = df.corr(numeric_only=True)
10
11 sns.heatmap(
12     corr,
13     annot=True,
14     cmap='coolwarm',
15     fmt='.2f'
16 )
17
18 plt.title('Matriz de Correlação')
19
20 plt.show()
```

5. Análise por gênero

Análise por gênero está verificando se existem diferenças entre homens e mulheres em relação à doença hepática e aos exames laboratoriais.

Análise por gênero

```
1 print("\n")
2 print("=" * 30)
3 print("ANALISE POR GÊNERO")
4 print("=" * 30, "\n")
5
6 # ANÁLISE POR GÊNERO
7 plt.title('Classe por Gênero')
8
9 plt.xlabel('0 = Feminino | 1 = Masculino')
10
11 plt.show()
12
13 # Bilirrubina por gênero
14 plt.figure(figsize=(8,5))
15
16 sns.boxplot(
17     x='Genero',
18     y='Bilirrubina_Total',
19     data=df
20 )
21
22 plt.title('Bilirrubina Total por Gênero')
23
24 plt.show()
25
26 # ALT por gênero
27 plt.figure(figsize=(8,5))
28
29 sns.boxplot(
30     x='Genero',
31     y='ALT',
32     data=df
```

```

30     x= 'genero' ,
31     y='ALT',
32     data=df
33 )
34
35 plt.title('ALT por Gênero')
36
37 plt.show()
38
39 # AST por gênero
40 plt.figure(figsize=(8,5))
41
42 sns.boxplot(
43     x='Genero',
44     y='AST',
45     data=df
46 )
47
48 plt.title('AST por Gênero')
49
50 plt.show()

```

- Correção do data leakage

Antes:

```

scaler = StandardScaler()

x_train = scaler.fit_transform(x_train)
x_val = scaler.transform(x_val)
x_test = scaler.transform(x_test)

# Modelos
models = {
    "Logistic Regression": LogisticRegression(max_iter=1000),
    "Random Forest": RandomForestClassifier(random_state=42),
    "Gradient Boosting": GradientBoostingClassifier(random_state=42)
}

```

Depois:

```

# Modelos
models = {
    "Logistic Regression":
        Pipeline([
            ('scaler', StandardScaler()),
            ('model', LogisticRegression(max_iter=1000))
        ]),
    "Random Forest":
        Pipeline([
            ('scaler', StandardScaler()),
            ('model', RandomForestClassifier(random_state=42))
        ]),
    "Gradient Boosting":
        Pipeline([
            ('scaler', StandardScaler()),
            ('model', GradientBoostingClassifier(random_state=42))
        ])
}

```

No modelo antigo tínhamos um vazamento de dados, pois a variável scaler calculava a media e o desvio padrão. No momento que o modelo era treinado utilizava todos os dados, inclusive os que

foram utilizados para calcular a média, porém não estavam dentro dos dados de treino, utilizando o pipeline todos os dados exceto os de treinos são “escondidos” acabando assim com o vazamento de dados.